# Actividad de clase: Regresión, Gradient Descent y Regularización

**Sin código!**

Durante toda la actividad trabajaremos con las siguientes observaciones:

| x | y |
|---|---|
| 0 | 1 |
| 1 | 3 |
| 2 | 4 |
| 3 | 7 |
| 4 | 8 |
| 5 | 12 |

## Parte 1: primer modelo

Nuestro objetivo es construir un modelo que permita predecir $y$ a partir de $x$.

Consideremos el modelo $\hat{y} = 1 + w\,x$. Comenzaremos utilizando $w = 1$

**Predicciones y errores:** complete la siguiente tabla

| x | y | $\hat{y}$ | $y - \hat{y}$ | $\lvert y - \hat{y} \rvert$ | $(y - \hat{y})^2$ |
|---|---|---|---|---|---|
| 0 | 1 | 1 | 0 | 0 | 0 |
| 1 | 3 | 2 | 1 | 1 | 1 |
| 2 | 4 | 3 | 1 | 1 | 1 |
| 3 | 7 | 4 | 3 | 3 | 9 |
| 4 | 8 | 5 | 3 | 3 | 9 |
| 5 | 12 | 6 | 6 | 6 | 36 |

Calcule:

$$\text{MAE} = \frac{1}{N}\sum_i |y_i - \hat{y}_i| \quad = 14/6 \approx \mathbf{2.33}$$

$$\text{MSE}= \frac{1}{N}\sum_i \left( y_i - \hat{y}_i \right)^2 \quad = 56/6 \approx \mathbf{9.33}$$

**Preguntas:**

- ¿El modelo tiende a sobreestimar o subestimar los valores observados?
- Mirando los residuos, ¿qué cambio harían en $w$ para mejorar el modelo?
- ¿Cómo podríamos decidir sistemáticamente cuánto modificar $w$?

1) Subestima: todos los residuos y − ŷ son ≥ 0 y crecen con x.
2) Aumentar w: el error crece con x, por lo que la pendiente es demasiado baja.
3) Con la derivada (gradiente) del costo respecto de w, que indica hacia dónde y cuánto disminuye el error.

## Parte 2. Mejorando el modelo

En lugar de elegir $w$ al azar, exploremos cómo cambia el error.
Calcule el MSE para los siguientes valores de $w$:

$$w = 1.0 \, , \, 1.5 \, , \, 2.0 \, , \, 2.5$$

Utilice $\hat{y} = 1 + w\,x$. Complete la tabla

| w | MSE |
|---|---|
| 1.0 | 9.333 |
| 1.5 | 2.625 |
| 2.0 | 0.500 |
| 2.5 | 2.958 |

**Preguntas**:

- ¿Al aumentar $w$, el MSE siempre disminuye? No: baja hasta w ≈ 2 y luego vuelve a subir.
- Si actualmente estamos en $w = 1$, ¿en qué dirección deberíamos movernos?
- Si estuviéramos en $w = 2.5$, ¿en qué dirección deberíamos movernos?
- A partir de los resultados de la tabla, ¿dónde parece encontrarse aproximadamente el mínimo del MSE?

•Hacia arriba.
Disminuir.
Cerca de w ≈ 2. El valor exacto es w* = Σx(y−1)/Σx² = 109/55 ≈ 1.98, con MSE ≈ 0.497.

## Parte 3. Una iteración de Gradient Descent

Hasta ahora hemos probado diferentes valores de $w$. Queremos ahora encontrar una manera sistemática de decidir cómo modificarlo.

Para nuestro modelo $\hat{y}_i = 1 + w\,x_i$, y utilizando MSE como función de costo

$$J(w) = \frac{1}{N}\sum_i (y_i - \hat{y}_i)^2$$

**Encuentre el gradiente de la función de costo respecto de $w$. Calcule inicialmente para $w = 1$.** $\partial J/\partial w = -(2/N)\,\Sigma\, x_i(y_i - 1 - w\,x_i)$

En $w = 1$: $\Sigma\, x_i(y_i - \hat{y}_i) = 0 + 1 + 2 + 9 + 12 + 30 = 54 \Rightarrow \partial J/\partial w = -(2/6)\cdot 54 = \mathbf{-18}$

**Según el signo del gradiente, ¿deberíamos aumentar o disminuir $w$?**

El gradiente es negativo ⇒ debemos **aumentar** w.

Gradient Descent actualiza el parámetro mediante:

$$w_{nuevo} = w_{anterior} - \eta\frac{\partial J}{\partial w}$$

Utilicen un learning rate de $\eta = 0.05$

- Calcule el nuevo valor de $w$. $w_{nuevo} = 1 - 0.05\cdot(-18) = \mathbf{1.9}$
- Calcule nuevamente las seis predicciones. $\hat{y} = 1.0, 2.9, 4.8, 6.7, 8.6, 10.5$
- Calcule el nuevo MSE. Residuos: 0, 0.1, −0.8, 0.3, −0.6, 1.5 ⇒ MSE = 3.35/6 ≈ **0.558**
- Compare el nuevo MSE con el obtenido inicialmente. 9.33 → 0.558 (≈ 17 veces menor)

**Preguntas:**

- ¿Mejoró el modelo? Sí: el MSE bajó de 9.33 a 0.558 y w = 1.9 queda cerca del óptimo (≈ 1.98).
- ¿Qué cree que ocurriría si el learning rate fuese extremadamente pequeño?
- ¿Qué cree que ocurriría si fuese demasiado grande?
- ¿Más iteraciones solucionarían necesariamente cualquiera de estos problemas?

- η muy pequeño: converge, pero muy lento (se necesitan muchísimas iteraciones).
- η muy grande: se pasa del mínimo, oscila y puede diverger (aquí diverge si η > 2/18.3 ≈ 0.11).
- Más iteraciones solo ayudan con η pequeño; con η grande empeoran, porque el error crece en cada paso.

## Parte 4. Métricas y errores

Consideremos ahora el modelo $\hat{y} = 1 + 2\,x$ y volvamos a los datos originales.

Calcule su MAE y MSE. $\hat{y} = 1, 3, 5, 7, 9, 11$; residuos 0, 0, −1, 0, −1, 1 ⇒ MAE = **0.50**, MSE = **0.50**

Suponga ahora que la última observación hubiese sido $(x, y) = (5, 20)$ en lugar de $(x, y) = (5, 12)$

**Antes de calcular: ¿Espera que el cambio afecte más al MAE o al MSE? ¿Por qué?** Más al MSE: eleva los errores al cuadrado, así que un error grande pesa mucho más.

Calcule nuevamente ambas métricas y complete la tabla

| Métrica | Datos originales | Con y=20 |
|---|---|---|
| MAE | 0.50 | 11/6 ≈ 1.83 |
| MSE | 0.50 | 83/6 ≈ 13.83 |

**Preguntas:**

- ¿Cuál de las dos métricas reaccionó más al punto extremo? ¿Por qué ocurre esto? El MSE (×28 vs ×3.7 del MAE): el residuo 9 aporta 81 al MSE y solo 9 al MAE.
- Si $y = 20$ fuese producto de un problema instrumental, ¿qué métrica preferirían para evaluar el modelo? El MAE: es robusto a outliers (y conviene limpiar el dato).
- ¿Cambiaría su respuesta si $y = 20$ fuese una observación real y científicamente interesante? Sí: no hay que ignorarlo; el MSE, sensible a ese punto, sería más apropiado.

## Parte 5. Qué significa un mejor modelo?

Volvamos nuevamente a los seis datos originales. Tenemos nuestro modelo lineal:

$$\text{Modelo A: } \hat{y} = 1 + 2\,x$$

$$\text{Para estos datos, } MSE_A = 0.50$$

Otro grupo propone utilizar un modelo mucho más flexible, un polinomio de grado 5:

$$\text{Modelo B: } \hat{y} = 1 + 8.45\,x - 11.875\,x^2 + \frac{83}{12}\,x^3 - 1.625\,x^4 + \frac{2}{15}\,x^5$$

Este modelo pasa exactamente por las seis observaciones:

$$MSE_B = 0$$

**¿Cuál de los dos modelos elegiría a partir de esta información? Justifique.**

El A: B tiene 6 parámetros para 6 datos e interpola también el ruido; A es más simple y casi igual de preciso.

Llegan nuevas observaciones. Después de construir los modelos obtenemos dos nuevas mediciones:

| x | y |
|---|---|
| 6 | 13 |
| 7 | 15 |

El Modelo A predice:

| x | Valor real | Predicción |
|---|---|---|
| 6 | 13 | 13 |
| 7 | 15 | 15 |

Mientras que el Modelo B predice aproximadamente:

| x | Valor real | Predicción |
|---|---|---|
| 6 | 13 | 49 |
| 7 | 15 | 190 |

**Preguntas:**

- ¿Cuál modelo tiene menor error sobre los datos utilizados para construirlo?
- ¿Cuál funciona mejor sobre las nuevas observaciones? El Modelo A.
- ¿Qué ocurrió con el Modelo B? Overfitting: memorizó el ruido y fuera del rango se dispara.
- ¿Por qué el MSE calculado sobre los datos originales (de entrenamiento) no fue suficiente para detectar este problema? Solo mide el ajuste a datos ya vistos.
- ¿Significa esto que los modelos más complejos son siempre peores?

• 1) Menor error en los datos de construcción: el Modelo B (MSE = 0).
•5) No: si el fenómeno es complejo, un modelo muy simple sufre underfitting; la complejidad debe ajustarse a los datos y controlarse con validación y regularización.

## Parte 6. Regularización

Una posibilidad es no evaluar un modelo únicamente por qué tan bien reproduce los datos, sino también considerar el tamaño de sus coeficientes.

Definimos una nueva función de costo:

$$J = MSE + \lambda \sum_j w_j^2$$

Utilizaremos $\lambda = 0.01$

Para el Modelo A, $MSE_A = 0.50$ y:

$$\sum_j w_j^2 = 2^2 = 4$$

Para el Modelo B, $MSE_B = 0$ y la suma de los cuadrados de sus coeficientes es aproximadamente:

$$\sum_j w_j^2 = 262.9$$

Calcule $J_A, J_B$ $J_A = 0.50 + 0.01 \cdot 4 =$ **0.54** $J_B = 0 + 0.01 \cdot 262.9 \approx$ **2.63**

**Preguntas:**

- ¿Qué modelo preferíamos cuando utilizábamos solamente el MSE? El Modelo B.
- ¿Qué modelo preferimos utilizando esta nueva función de costo? El Modelo A.
- El Modelo A tiene mayor error de entrenamiento. ¿Por qué podríamos estar dispuestos a aceptarlo? Coeficientes chicos: modelo más suave que generaliza mejor.
- ¿Qué ocurriría si $\lambda = 0$? Volvemos a usar solo el MSE: elegiríamos B.
- ¿Qué esperan que ocurra si $\lambda$ es muy grande? Coeficientes → 0: underfitting.
- ¿Aumentar $\lambda$ siempre debería mejorar el modelo?

• Aumentar λ no siempre mejora: existe un λ intermedio óptimo; λ es un hiperparámetro y se elige con validación, no con el conjunto de prueba.

## Final

¿Cuál es la diferencia entre elegir un modelo, ajustar sus parámetros y elegir qué significa que un ajuste sea “bueno”?

**Elegir un modelo** es escoger la familia de funciones posibles (lineal, polinomio de grado d, SVM con cierto kernel), incluidos hiperparámetros como el grado o λ, que se eligen con validación. **Ajustar sus parámetros** es encontrar, dentro de esa familia, los valores (w, b) que minimizan la función de costo sobre los datos de entrenamiento, por ejemplo con gradient descent. **Elegir qué significa que un ajuste sea bueno** es definir la función de costo o métrica (MSE, MAE, con o sin regularización): es una decisión que codifica qué errores importan más y puede cambiar cuál modelo resulta “mejor”.